

STANDAR OPERASIONAL PROSEDUR (SOP)

Kode Dokumen:	SOP-AI-DEPLOY-001
Judul:	Deployment Model Machine Learning (Production)
Revisi Terakhir:	24 Mei 2026

1. TUJUAN

Prosedur ini bertujuan untuk memberikan standarisasi langkah-langkah dalam mendistribusikan (deploy) model Machine Learning dari tahap Staging ke Production agar meminimalisir downtime dan memastikan stabilitas layanan.

2. RUANG LINGKUP

SOP ini mencakup persiapan environment (infrastruktur GPU/CPU), pengambilan container dari registry, penyesuaian environment variables, peluncuran service, dan prosedur rollback apabila terjadi critical error.

3. PRASYARAT (PRE-REQUISITES)

- Akses SSH ke Production Server (Node AI).
- Docker Engine (versi $\geq$ 24) dan NVIDIA Container Toolkit sudah terinstal (untuk GPU instance).
- Akses ke Private Container Registry (contoh: AWS ECR, GitLab Registry).
- Approval dari Lead Engineer / IT Manager yang tercatat di tiket JIRA.

4. LANGKAH KERJA DEPLOYMENT

Tahap 1: Pulling Model Image

- Login ke private registry.

```
docker login registry.perusahaan.com -u deploy_user -p $TOKEN
```

- Tarik image model versi terbaru sesuai tag rilis.

```
docker pull registry.perusahaan.com/ai-service/recsys-model:v2.1.0
```

Tahap 2: Konfigurasi Environment

- Backup file .env yang sedang berjalan.

```
cp /opt/ai-services/.env /opt/ai-services/.env.backup_$(date +%F)
```

- Perbarui variabel `MODEL\_VERSION`, `API\_KEY\_CORE`, dan `FEATURE\_STORE\_URL` sesuai

kebutuhan rilis.

Taha

- Gunakan Docker Swarm atau Docker Compose dengan flag rebuild.

```
docker-compose up -d --no-deps --build ai-recsys-service
```

- Tunggu proses inisialisasi model (loading weights ke GPU/RAM), yang dapat memakan waktu 1-3 menit.

5. POST-DEPLOYMENT & MONITORING

- Cek status container pastikan berstatus 'Up (Healthy)'.

```
docker ps | grep ai-recsys-service
```

- Lakukan Health Check secara manual ke endpoint Liveness Probe.

```
curl -I https://ai.perusahaan.com/health
```

- Pantau grafik penggunaan GPU (menggunakan `nvidia-smi`) dan CPU/RAM di Grafana Dashboard selama 15 menit pertama.
- Pastikan tidak ada HTTP 500 error yang melonjak secara anomali pada API Gateway metrics.

6. PROSEDUR ROLLBACK

Apabila dalam 15 menit pertama ditemukan Critical Error (Error Rate > 5% atau Latency > 2000ms), lakukan Rollback segera dengan langkah berikut:

- Hentikan service versi terbaru.

```
docker-compose stop ai-recsys-service
```

- Kembalikan konfigurasi file .env menggunakan file backup.

```
cp /opt/ai-services/.env.backup_* /opt/ai-services/.env
```

- Ubah tag image di docker-compose.yml kembali ke versi sebelumnya yang stabil (contoh: v2.0.9).
- Jalankan ulang service.

```
docker-compose up -d ai-recsys-service
```

- Laporkan insiden kegagalan deployment ini ke channel Slack #incident-response.